Отчет по тестовому заданию номер 2

Анализ токсичности комментариев: NLP предобработка и статистический анализ

Выполнил: Кравцев Вадим
Инструментарий: Python (Pandas, NLTK, Scikit-learn)

23 февраля 2026 г.

Содержание

1 Введение **2**

2 Описание задачи **2**

3 Описание решения **2**

3.1 Предобработка данных 2

3.2 Математическая модель: TF-IDF 2

4 Реализация **2**

5 Результаты анализа **3**

6 Заключение **3**

1 Введение

Целью данного проекта является проведение лингвистического и статистического анализа набора данных, содержащего комментарии пользователей. Основная задача — выявить ключевые лексические маркеры, характерные для токсичных и нейтральных высказываний, используя методы обработки естественного языка (NLP).

2 Описание задачи

Согласно техническому заданию, необходимо реализовать следующий пайплайн:

1. Загрузка и первичная обработка данных.
2. Очистка текста от спецсимволов и цифр.
3. Лемматизация текста (приведение к начальной форме).
4. Удаление стоп-слов.
5. Векторизация с использованием метрики TF-IDF.
6. Анализ распределения топ-10 значимых слов.

3 Описание решения

3.1 Предобработка данных

Для минимизации шума в данных была проведена очистка с помощью регулярных выражений (Regex), в результате которой были удалены пунктуация и числа. Далее была применена **лемматизация** (библиотека NLTK, WordNetLemmatizer). В отличие от стемминга, лемматизация учитывает контекст слова, что позволяет сохранить семантическую точность (например, «feet» преобразуется в «foot»).

3.2 Математическая модель: TF-IDF

Для векторизации текста использовалась мера **TF-IDF** (Term Frequency – Inverse Document Frequency). Она позволяет оценить важность слова в контексте конкретного документа относительно всего корпуса.

Формула расчета веса слова t в документе d:

$$w_{t,d} = TF(t,d) \times \log \frac{N}{DF(t)} \tag{1}$$

Где:

- $TF(t,d)$ — частота слова в документе.
- N — общее количество документов.
- $DF(t)$ — количество документов, содержащих данное слово.

Для корректного сравнения комментариев разной длины применена **L2-нормализация** векторов.

4 Реализация

Ниже представлен основной фрагмент кода для обработки данных:

```python
def process_text(df):
    lemmatizer = WordNetLemmatizer()
    stop_words = set(stopwords.words('english'))

    #
    df['clean'] = df['text'].apply(lambda x: re.sub(r'[^a-zA-Z\s]', '', str(x).lower()))
    df['final'] = df['clean'].apply(lambda x: " ".join(
        [lemmatizer.lemmatize(w) for w in x.split() if w not in stop_words]
    ))
    return df
```

Листинг 1: Обработка текста и расчет TF-IDF

5 Результаты анализа

В ходе работы были построены распределения наиболее значимых слов на основе весов TF-IDF.

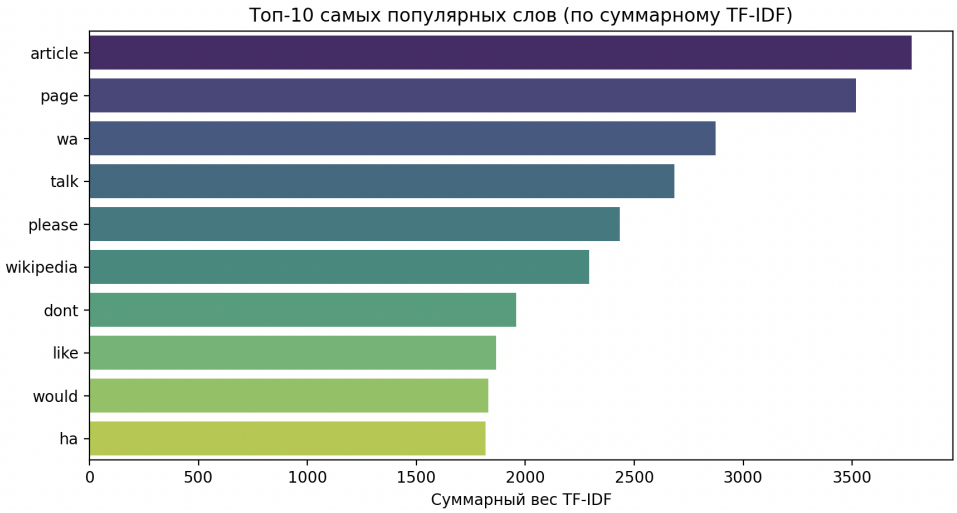

Рис. 1: Топ-10 самых популярных слов во всем корпусе

На рисунке 1 представлены наиболее весомые лексемы всего набора данных. Далее приведено сравнение между нейтральными и токсичными комментариями.

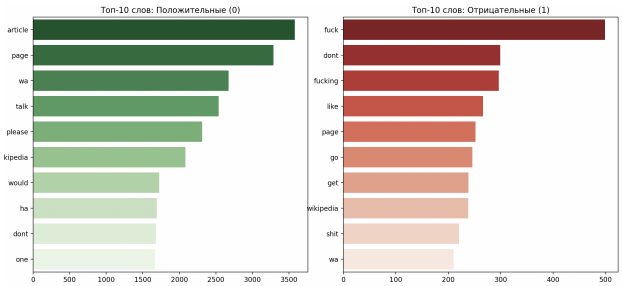

Рис. 2: Нейтральные комментарии

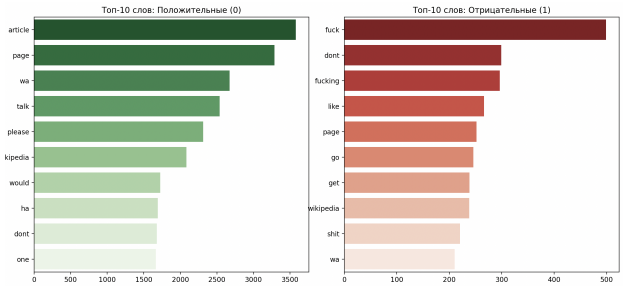

Рис. 3: Токсичные комментарии

- **Нейтральные комментарии (0):** Преобладают слова конструктивного обсуждения: *article, edit, please, source, talk.*
- **Токсичные комментарии (1):** Наблюдается выраженный лексический сдвиг в сторону агрессивной лексики.

Это подтверждает гипотезу о том, что выбранные методы предобработки эффективно выделяют дискриминативные признаки для задачи классификации текстов.

6 Заключение

В проекте был реализован полный цикл подготовки текстовых данных. Применение лемматизации в сочетании с TF-IDF векторизацией показало свою эффективность для разведочного анализа данных. Данный пайплайн может служить основой для построения классификатора на базе машинного обучения.